

Dự đoán mức độ ùn tắc trên các tuyến đường trên địa bàn Thành phố Hồ Chí Minh

Hoàng Lê Anh Khoa^{1,2}, Lê Vĩnh Kỳ^{1,2}, Ngô Nhất Khánh^{1,2}

¹Trường Đại học Công nghệ thông tin

²Đại học Quốc gia Thành phố Hồ Chí Minh - Việt Nam

{22520667,22520730,22520640}@gm.uit.edu.vn

Abstract

Hiện nay, ùn tắc giao thông đã và đang là một vấn đề lớn ở những đô thị lớn, đặc biệt là Thành phố Hồ Chí Minh. Vấn đề này không chỉ gây lãng phí thời gian và gia tăng ô nhiễm môi trường mà còn ảnh hưởng tiêu cực đến chất lượng sống của người dân. Nhiều công trình nghiên cứu về lưu lượng giao thông đã được phát triển để giải quyết những vấn đề này. Trong nghiên cứu này, chúng tôi đã xây dựng và triển khai ứng dụng dự đoán mức độ ùn tắc giao thông dựa trên kiến trúc mô hình Transformer, kết quả cho thấy rằng mô hình dự đoán khá tốt.

Mã nguồn của ứng dụng, bao gồm phần giao diện, server và mô hình được công khai tại [GitHub](#).

1 Giới thiệu

Ùn tắc giao thông là một vấn đề lớn quan trọng và cấp bách tại các đô thị lớn trên toàn thế giới, đặc biệt là ở Thành phố Hồ Chí Minh (TpHCM), nơi tình trạng ùn tắc giao thông diễn ra thường xuyên, ảnh hưởng đến chất lượng sống, kinh tế và môi trường.

Trong bối cảnh đó, việc áp dụng các công nghệ tiên tiến như trí tuệ nhân tạo (AI) và dữ liệu lớn (Big Data) trong quản lý và dự đoán giao thông đã mở ra những cơ hội mới. Các hệ thống dự đoán giao thông hiện đại không chỉ giúp nhận diện và dự đoán các điểm ùn tắc trong tương lai mà còn hỗ trợ lập kế hoạch giao thông hiệu quả hơn, cải thiện sự lưu thông và giảm thiểu tác động tiêu cực.

Bài báo này trình bày một phương pháp tiếp cận mới trong việc dự đoán mức độ ùn tắc giao thông tại Thành phố Hồ Chí Minh, sử dụng và cải tiến các mô hình có kiến trúc **Transformer** (Vaswani, 2017) để các mô hình phát huy hiệu quả hơn trên nhiệm vụ dự đoán ùn tắc giao thông. Mục tiêu là xây dựng một hệ thống có khả năng dự đoán tình trạng giao thông trong thời gian thực, hỗ trợ các nhà quản lý giao thông đưa ra quyết định kịp thời và người tham gia giao thông có thể lựa chọn lộ

trình phù hợp. Thông qua việc tận dụng dữ liệu từ nhiều nguồn khác nhau, hệ thống không chỉ mang lại độ chính xác cao mà còn phù hợp với điều kiện thực tế của TpHCM, nơi có mạng lưới giao thông phức tạp và thay đổi liên tục.

2 Các công trình liên quan

Trong những năm gần đây, nhiều nghiên cứu đã tập trung vào việc dự đoán tình trạng giao thông sử dụng các phương pháp tiên tiến trong trí tuệ nhân tạo và học sâu:

(Yin et al., 2021) tổng hợp các phương pháp học sâu trong dự đoán giao thông, bao gồm mô hình CNN (Convolutional Neural Network) để trích xuất đặc trưng không gian, GCN (Graph Convolution Network) nhằm mô hình hóa các mối quan hệ trong mạng lưới giao thông phức tạp và RNN, bao gồm các biến thể LSTM, GRU với mục đích xử lý các phụ thuộc thời gian trong dữ liệu chuỗi thời gian.

(Meena et al., 2020) tập trung vào việc phát triển một hệ thống dự đoán lưu lượng giao thông thông minh sử dụng các mô hình học máy (Linear Regression, SVM, Decision Trees, KNN) và học sâu (ANN). Các mô hình này phân tích dữ liệu từ cảm biến, GPS, và camera giao thông, hỗ trợ dự đoán thời gian di chuyển, lập kế hoạch tuyến đường và cảnh báo sớm về ùn tắc. Bài báo cũng sử dụng thuật toán di truyền để tối ưu hóa tham số mô hình và lựa chọn đặc trưng quan trọng. Hệ thống hướng đến cải thiện hiệu quả vận hành giao thông đô thị, nhưng hiệu quả của nó phụ thuộc nhiều vào chất lượng dữ liệu và khả năng xử lý các tình huống giao thông bất thường.

Các mô hình truyền thống và học sâu đã đặt nền tảng quan trọng cho nghiên cứu dự đoán giao thông, mỗi phương pháp có ưu và nhược điểm riêng. Tuy nhiên, sự ra đời của

Transformer (Vaswani, 2017) mở ra một hướng đi mới cho bài toán dự đoán chuỗi thời gian nói chung và bài toán dự đoán giao thông nói riêng. Nhiều mô hình dự đoán chuỗi thời gian dựa trên kiến trúc mô hình Transformer đã thể hiện được khả năng của mình khi đạt được state of the art trên nhiều benchmark datasets. Tiêu biểu có thể kể đến như Reformer (Kitaev et al., 2020), Autoformer (Wu et al., 2021), PatchTST (Nie et al., 2023), iTransformer (Liu et al., 2023), TimeXer (Wang et al., 2024).

3 Phương pháp

3.1 Dữ liệu

Trong nghiên cứu này, chúng tôi sử dụng bộ dữ liệu PEMS-Bay, được công bố tại (Li et al., 2018). Đây là một tập dữ liệu nổi tiếng được thu thập từ hệ thống giám sát giao thông của bang California, Hoa Kỳ. Bộ dữ liệu PEMS-Bay bao gồm thông tin về lưu lượng và tốc độ giao thông, được ghi nhận tại 325 trạm cảm biến đặt dọc theo các tuyến đường trong khu vực Vịnh San Francisco. Dữ liệu được thu thập liên tục với tần suất 5 phút, bao gồm các đặc trưng quan trọng như thời gian, vị trí địa lý của trạm, và thông tin về giao thông thời gian thực. Bộ dữ liệu này không chỉ thể hiện tính đa chiều mà còn chứa đựng các đặc điểm quan trọng về không gian và thời gian, giúp chúng tôi khai thác các mô hình học sâu và phương pháp phân tích tiên tiến để nghiên cứu và dự đoán lưu lượng giao thông.

3.2 TimeXer

Trong dự đoán chuỗi thời gian đa biến, các điểm dữ liệu trong quá khứ

$$\{\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_T\} \in R^{T \times N}\}. \quad (1)$$

Trong đó T là số bước thời gian và N là số biến. Từ đó chúng tôi dự đoán S bước thời gian tương lai $\mathbf{Y} = \{\mathbf{x}_{T+1}, \dots, \mathbf{x}_T\} \in R^{T \times N}$.

Trong nghiên cứu này. Chúng tôi chọn mô hình TimeXer (Wang et al., 2024) để cải tiến thêm về khả năng dự đoán giao thông. Mô hình có kiến trúc như Hình 1 bên dưới. Mô hình gồm 2 lớp Attention là Self Attention và Cross Attention để giải quyết 2 loại biến trong bài toán dự đoán chuỗi thời gian là Biến nội và Biến ngoại.

Đầu tiên, các biến nội sẽ đi qua 1 lớp mã hóa để được mã hóa thành các patch có chiều dài giống nhau, còn các biến ngoại sẽ đi qua lớp mã hóa để được chiếu toàn bộ các bước thời gian qua cùng 1 không gian. Tiếp theo, các patch nhỏ trong biến

nội sẽ được đi qua 1 lớp Self Attention để mô hình học được các đặc trưng thời gian ảnh hưởng với nhau. 1 biến Global Token có độ lớn ngang 1 patch sẽ được gắn vào. Kế đến, biến Global Token này sẽ được đi qua lớp Cross Attention với các biến ngoại (đã được mã hóa thành cùng 1 chiều) để biến Global Token học được ảnh hưởng của các biến ngoại này lên biến nội. Global Token giúp mô hình chọn lọc ra được cường độ ảnh hưởng của các biến ngoại đến biến nội trong lớp Self Attention ở lớp Encoder kế tiếp. Việc gồm nhiều lớp Attention để học các ảnh hưởng từ biến nội và biến ngoại đã khiến cho TimeXer đạt được state of the art trên nhiều benchmark dataset.

3.3 Cải tiến

TimeXer thể hiện tốt trên nhiều benchmark datasets, tuy nhiên mô hình vẫn chưa học được các đặc trưng về không gian, các kết nối phức tạp giữa các tuyến đường. Dù kiến trúc Transformer giúp mô hình học được các quan hệ phức tạp giữa các biến, tuy nhiên với những mối quan hệ phức tạp của các kết nối trong hệ thống giao thông thì mô hình cần nhiều cách để hiểu được hơn là chỉ dùng cơ chế Attention thông thường của Transformer.

Mạng lưới giao thông có thể được mô phỏng thành một ma trận khoảng cách \mathbf{D} , trong đó phần tử D_{ij} đại diện cho khoảng cách từ cảm biến i đến cảm biến j . Ma trận này được định nghĩa như sau:

$$D_{ij} = \begin{cases} 0, & \text{nếu } i = j \\ \text{dist}(i, j), & \text{nếu } i \text{ và } j \text{ có thể kết nối nhau} \\ \infty, & \text{nếu không tồn tại kết nối giữa } i \text{ và } j. \end{cases} \quad (2)$$

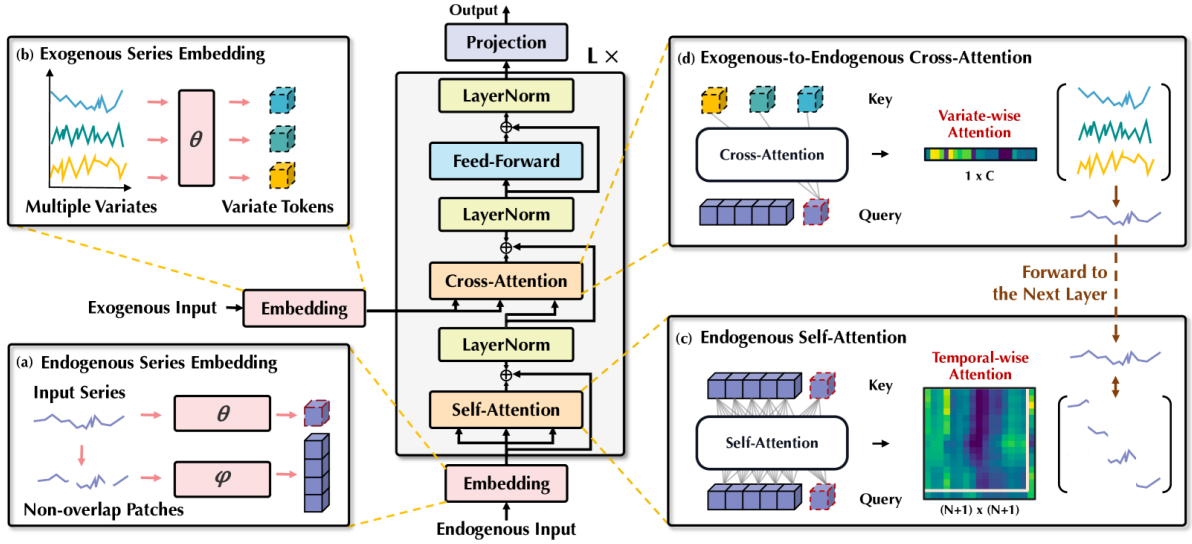
Ở đây, $\text{dist}(i, j)$ là khoảng cách tối thiểu giữa i và j , được tính toán bằng thuật toán Dijkstra trên đồ thị mạng lưới giao thông. Khoảng cách $\text{dist}(i, j)$ giữa hai nút i và j được xác định là:

$$\text{dist}(i, j) = \min \left(\sum_{e \in P} w(e) \right) \quad (3)$$

Trong trường hợp không tồn tại bất kỳ đường đi nào giữa i và j , giá trị D_{ij} được đặt là ∞ .

Sau khi đã có được \mathbf{D} , công thức Attention ở bước Cross Attention sẽ được biểu diễn như sau:

$$\text{Attention} = \text{Softmax} \left(\frac{\mathbf{Q} \cdot \mathbf{K}^\top}{\sqrt{d_k}} + \exp(-\mathbf{D}^2) \cdot \mathbf{W}_d \right) \cdot \mathbf{V} \quad (4)$$



Hình 1: Kiến trúc mô hình TimeXer

Việc dùng hàm $\exp(-z)$ sẽ giúp mô hình gia tăng thêm 1 ít trọng số Attention cho 2 biến nếu 2 biến này ở gần nhau. Khi z sát về 0 (nghĩa là 2 vị trí này gần nhau) thì hàm sẽ đạt cực đại, còn nếu z tiến về vô cực (nghĩa là 2 tuyến đường này không thể kết nối) thì hàm giảm về 0. Sau đó được nhân với 1 trọng số để điều chỉnh mức độ ảnh hưởng đến Attention

4 Thực nghiệm và kết quả

4.1 Thiết lập

Trong phần này, chúng tôi tiến hành các thử nghiệm so sánh các mô hình với nhau trên cùng 1 tập dữ liệu để đánh giá hiệu suất dự báo của mô hình trên tập dữ liệu giao thông.

Baseline: Chúng tôi thực hiện so sánh phương pháp của mình với các mô hình dựa trên kiến trúc Transformer, bao gồm 4 mô hình được biết đến rộng rãi bao gồm Transformer (Vaswani, 2017), Autoformer (Wu et al., 2021), iTransformer (Liu et al., 2023), TimeXer (Wang et al., 2024)

Chúng tôi sử dụng các tham số có giá trị như sau: $seq_len = 96$, $pred_len = 12$, $d_model = 256$, $encoder_layers = 4$, $batch_size = 32$, $batch_len = 12$, $learning_rate = 1e-3$.

4.2 Kết quả phân tích

Sau khi thực nghiệm trên nhiều mô hình bằng GPU Nvidia Tesla P100, chúng tôi thu được kết quả như bảng 1

Kết quả từ bảng so sánh cho thấy mô hình

Model	MSE	MAE
Transformer	20.12	2.43
Autoformer	18.21	2.38
iTransformer	17.87	2.24
TimeXer	15.97	1.98
TimeXer (cải tiến)	14.75	1.92

Bảng 1: Kết quả so sánh bao gồm MSE và MAE của mô hình và các baseline

TimeXer (cải tiến) vượt trội hơn so với các mô hình khác trong bài toán dự báo chuỗi thời gian. Với giá trị MSE là 14.75 và MAE là 1.92, **TimeXer (cải tiến)** đạt độ chính xác cao nhất, cải thiện đáng kể so với phiên bản gốc của TimeXer và các mô hình tiên tiến khác như Transformer, Autoformer và iTransformer.

Những kết quả này cho thấy rằng các cải tiến được đề xuất đã giúp TimeXer nâng cao khả năng học tập các quan hệ về không gian địa lý. Điều này khẳng định tiềm năng của việc tích hợp thông tin về không gian địa lý và các kết nối vào các mô hình kiến trúc Transformer thay vì để mô hình học theo cách truyền thống.

5 Kết luận và hướng phát triển

Qua quá trình nghiên cứu để cải thiện hiệu suất của các mô hình có kiến trúc transformer Transformer trong bài toán dự đoán lưu lượng giao thông, chúng tôi đã thành công trong việc cải thiện hiệu suất của mô hình tốt hơn trên dataset về giao thông bằng cách mã hóa thêm thông tin về địa lý và kết nối của

các tuyến đường vào Attention trong các mô hình kiến trúc Transformer. Điều này thể hiện tầm quan trọng của việc chủ động mã hóa thêm thông tin địa lý trong bài toán dự đoán giao thông thay vì để mô hình tự học. Qua quá trình nghiên cứu, nhóm đã thành công cải thiện hiệu suất và đạt state-of-the-art trên các nhóm mô hình Transformer. Điều này mở ra hướng nghiên cứu cho tương lai để có thể vượt qua được các mô hình chuyên biệt để dự đoán lưu lượng giao thông.

transformers with Auto-Correlation for long-term series forecasting. In *Advances in Neural Information Processing Systems*.

Xueyan Yin, Genze Wu, Jinze Wei, Yanming Shen, Heng Qi, and Baocai Yin. 2021. Deep learning on traffic prediction: Methods, analysis, and future directions. *IEEE Transactions on Intelligent Transportation Systems*, 23(6):4927–4943.

References

Hongyan Dui, Songru Zhang, Meng Liu, Xinghui Dong, and Guanghan Bai. 2024. [Iot-enabled real-time traffic monitoring and control management for intelligent transportation systems](#). *IEEE Internet of Things Journal*, 11(9):15842–15854.

Nikita Kitaev, Lukasz Kaiser, and Anselm Levskaya. 2020. [Reformer: The efficient transformer](#). In *International Conference on Learning Representations*.

Yaguang Li, Rose Yu, Cyrus Shahabi, and Yan Liu. 2018. Diffusion convolutional recurrent neural network: Data-driven traffic forecasting. In *International Conference on Learning Representations (ICLR '18)*.

Yong Liu, Tengge Hu, Haoran Zhang, Haixu Wu, Shiyu Wang, Lintao Ma, and Mingsheng Long. 2023. [itransformer: Inverted transformers are effective for time series forecasting](#). *arXiv preprint arXiv:2310.06625*.

Gaurav Meena, Deepanjali Sharma, and Mehul Mahrishi. 2020. Traffic prediction for intelligent transportation system using machine learning. In *2020 3rd International Conference on Emerging Technologies in Computer Engineering: Machine Learning and Internet of Things (ICETCE)*, pages 145–148. IEEE.

Yuqi Nie, Nam H. Nguyen, Phanwadee Sinthong, and Jayant Kalagnanam. 2023. A time series is worth 64 words: Long-term forecasting with transformers. In *International Conference on Learning Representations*.

A Vaswani. 2017. Attention is all you need. *Advances in Neural Information Processing Systems*.

Yuxuan Wang, Haixu Wu, Jiaxiang Dong, Guo Qin, Haoran Zhang, Yong Liu, Yunzhong Qiu, Jianmin Wang, and Mingsheng Long. 2024. [Timexer: Empowering transformers for time series forecasting with exogenous variables](#). *arXiv preprint arXiv:2402.19072*.

Haixu Wu, Jiehui Xu, Jianmin Wang, and Mingsheng Long. 2021. [Autoformer: Decomposition](#)